

文章编号:1001-7372(2021)12-0262-14

基于轨迹数据的共享电动自行车逆行 风险行为影响因素研究

边 扬¹, 杨家夏^{1,2}, 赵晓华^{*1}, 张晓龙¹, 韩唐姗¹

(1. 北京工业大学 交通工程北京市重点实验室, 北京 100124;

2. 华南理工大学 土木与交通学院, 广东 广州 510641)

摘要:为改善电动自行车带来的交通安全问题,研究逆行风险行为与其影响因素间的相关关系。基于长沙市芙蓉区共享电动自行车GPS轨迹数据,实现逆行行为的精准识别,采用机器学习CatBoost模型与SHAP可解释机器学习框架,从道路条件、交通状态、土地利用性质等方面开展逆行行为影响要素挖掘及作用解析。研究结果表明:CatBoost模型能够有效预测路段逆行频次并提取逆行行为的重要影响因素,主要包括出行时段、公共交通设施、土地利用性质、道路条件及交通状态等;从出行时段来看,工作日、早晚高峰时段更容易发生逆行;从公共交通设施与土地利用性质来看,道路周围公交站地铁站出口数量及餐饮、公司、购物等设施数量与逆行频次呈现非线性影响关系,在一定范围内设施数量与逆行行为存在正影响作用;从道路条件来看,过街通道间距在50~400 m时不易发生逆行,在非机动车道无物理隔离设施或过街通道间距在400~600 m时容易发生逆行,间距大于600 m时作用不稳定;从路段机非分隔形式来看,护栏分隔的逆行概率较低,绿化带分隔的逆行概率较高;从交通状态来看,当骑行速度、加速度较低或较高时与逆行行为负相关,当骑行速度在6~16 km·h⁻¹及加速度在0.3~1.0 m·s⁻²时与逆行行为正相关。研究成果可为共享电动自行车风险骑行行为辨识、非机动车交通安全管理提供有效的技术支持。

关键词:交通工程;逆行影响因素;可解释机器学习;共享电动自行车;轨迹数据;CatBoost模型

中图分类号:U491 **文献标志码:**A

Research on Influencing Factors of Reverse Riding Risk Behavior of Shared E-bike Based on Trajectory Data

BIAN Yang¹, YANG Jia-xia^{1,2}, ZHAO Xiao-hua^{*1}, ZHANG Xiao-long¹, HAN Tang-shan¹

(1. Beijing Key Laboratory of Traffic Engineering, Beijing University of Technology, Beijing 100124, China;

2. School of Civil Engineering & Transportation, South China University of Technology,
Guangzhou 510641, Guangdong, China)

Abstract: In order to improve the traffic safety problems caused by electric bicycles, this paper studies the relationship between reverse riding risk behavior and its influencing factors. Based on the GPS trajectory data of shared E-Bike in Furong district, Changsha City, the accurate identification of reverse riding behavior is realized. The machine learning model CatBoost and interpretable machine learning framework SHAP are used to extract and analyze the influencing

收稿日期:2021-05-01

基金项目:国家自然科学基金项目(52072012)

作者简介:边 扬(1980-),女,山东淄博人,副教授,工学博士,E-mail:bianyang@bjut.edu.cn。

* 通讯作者:赵晓华(1971-),女,山西太谷人,教授,博士研究生导师,工学博士,E-mail:zhaoxiaohua@bjut.edu.cn。

factors of reverse riding behavior from the aspects of road conditions, traffic conditions, land use attributes, etc. The results show that: ① CatBoost model can effectively predict the reverse riding frequency of road sections and extract the important influencing factors of reverse riding behavior, mainly including travel time, public transport facilities, land use attributes, road conditions and traffic conditions. ② In terms of travel time, reverse riding is more likely to occur on weekdays and morning & evening peak hours; In terms of public transport facilities and land use attributes, the number of bus stops and subway station exits, and the number of restaurants, companies, shopping and other facilities around the roads present a non-linear influence relationship to the reverse riding frequency. In a certain range, the number of facilities has a positive effect on the reverse riding behavior. In terms of road conditions, reverse riding is less likely to happen with road crossing intervals of 50~400 m. But reverse riding is more likely to happen when there are no physical separation facilities in the bicycle lane or with road crossing intervals of 400~600 m. And the effect is unstable when the intervals is wider than 600 m. In terms of bicycle lane, the reverse riding probability with guardrail separation is lower, while the probability with green belt separation is higher. In terms of traffic conditions, when the riding speed and acceleration are too low or too high, it is negatively related to the reverse riding behavior. When the riding speed is between 6~16 km · h⁻¹ and the acceleration is between 0.3~1.0 m · s⁻², it is positively related to the reverse riding behavior. This research can provide an effective technical support for the identification of shared E-Bike risk riding behavior, as well as for the management of non-motor vehicle traffic safety.

Keywords: traffic engineering; reverse riding influencing factor; interpretable machine learning; shared E-Bike; trajectory data; CatBoost model

Received 01 May 2021

Funding: National Natural Science Foundation of China (52072012)

* Corresponding author. *E-mail address:* zhaoxiaohua@bjut.edu.cn.

<https://doi.org/10.19721/j.cnki.1001-7372.2021.12.020>

0 引 言

电动自行车以其行驶速度快、方便舒适、节能环保等优点,成为 3~10 km 中短距离通勤、消费性出行的首选交通工具^[1]。近年来中国电动自行车发展迅速,截止 2019 年,电动自行车社会保有量接近 3 亿 veh^[2]。随着移动互联网技术的快速发展,以共享单车和共享电动自行车为代表的新兴服务行业应运而生,截止 2019 年,中国共享电动自行车车辆投放规模已超过 100 万 veh^[3]。

然而,电动自行车使得出行便利的同时也带来了一定安全风险。2019 年驾驶电动车自行车造成的事故占非机动车事故的 80% 以上,死亡人数达到 8 639 人,接近非机动车死亡人数的 70%^[4],给城市交通安全管理与保障带来了巨大的挑战。同时,共享电动自行车的安全问题受到了更为广泛的关注。2017 年 8 月,中国交通运输部等 10 个部门联合印

发《关于鼓励和规范互联网租赁自行车发展的指导意见》(交运发[2017]109 号)明确提出“不鼓励发展互联网租赁电动自行车”。其后,各地纷纷出台相应政策措施,规范共享电动自行车发展。例如北京、上海、西安等城市禁止共享电动自行车投放运营,长沙等城市严格限制投放区域和数量,南宁等城市无明确限制发展仅要求规范管理。可见,各地对于共享电动自行车的发展定位、投放规模范围等政策措施存在明显差异,尚未形成一致性管理办法。为了促进其健康可持续发展,有必要针对共享电动自行车的安全影响开展深入的研究和分析。

风险骑行行为作为电动自行车的重要安全隐患备受关注,有学者指出约 1/4 非机动车与机动车间的交通冲突是由非机动车骑行者的风险行为造成的^[5]。王曼丽等^[6-8]通过实地或录像调查发现电动自行车骑行人在骑行过程中存在超速、逆行、侵占机动车道和人行道、闯红灯、强行超车、突然停车或转

弯等多种风险骑行行为;赵桂范等^[9]分析人-车-路闭环系统对电动自行车安全性产生显著影响的因素,结果表明车辆运行速度、车辆运动状态、车辆类型、道路类型和道路条件是影响电动自行车安全性的重要因素。值得注意的是,逆行是一种与安全密切相关的风险骑行行为^[10]。非机动车骑行者为方便到达目的地,常采取逆向骑行的行为^[11]。Stimpson 等^[12]在研究 2012 年加利福尼亚州综合交通记录系统收集的自行车-汽车碰撞记录时发现,大约 12% 的碰撞由自行车逆行引起。李岩等^[13]研究非机动车骑行者逆行时的安全生理学特性,指出逆行时行驶速度和心率变异性降低、心率升高,不利于骑行者健康和交通安全。因此,逆行风险行为对交通安全的负面影响不容忽视。

近年来,随着移动互联网飞速发展,共享单车和共享电动自行车内置 GPS 系统能够全天候、高精度、细粒度采集骑行轨迹,突破传统研究中骑行行为难以观察的瓶颈。大规模的骑行轨迹数据为研究风险骑行行为提供了一种新途径,有助于利用大数据探究多种因素对逆行行为的影响。针对共享单车骑行轨迹的研究,Lu 等^[14]基于加拿大安大略省汉密尔顿的 750 veh 共享单车 GPS 轨迹数据研究自行车绕行行为;Romanillos 等^[15]利用西班牙马德里共享单车轨迹数据探索共享单车不同时段道路网络分布及不同用户的骑行模式。针对共享电动自行车,Li 等^[16]以山东省滕州市 1 周的共享电动自行车 GPS 数据为基础,观察轨迹的不连续性、不均匀性和骑行状态的稀疏特征;Wamburu 等^[17]利用美国纽约的共享电动自行车公开数据集,分析电动自行车出行替代及其碳效益;Langford 等^[18]基于 GPS 轨迹数据同时比较了共享单车与共享电动自行车的风险骑行行为,结果表明共享单车和共享电动自行车具有相似的骑行行为,并且都有较高的违规率。以上研究基于轨迹数据应用传统统计分析方法探究了出行行为特征,但缺乏对风险骑行行为影响规律的深入挖掘和探索。随着机器学习的广泛应用,复杂条件下风险骑行行为影响因素挖掘出现新的机遇。马晓磊等^[19-20]针对共享单车逆行行为提出了一种基于 GPS 轨迹的检测方法,并基于负二项加性决策树研究建成环境对共享单车逆行行为产生的影响。结果表明公司、公共汽车站、地铁站、住宅区和餐饮设施是高峰时段影响共享单车逆行行为的主要因素,而且这些因素对逆行频次的影响是非线性的。这些研究均为共享电动自行车逆行行为的深入探索

提供了借鉴和参考。

此外,机器学习模型可以识别自变量与因变量间复杂的非线性关系,能够较好地预测风险。国内外已有不少研究使用基于梯度提升决策树的复杂模型建模(如 XGBoost^[21]、LightGBM^[22]和 CatBoost^[23]),并结合 SHAP 可解释性机器学习框架挖掘特征变量的影响作用^[24-25]。Anghel 等^[26]对比研究了这 3 种机器学习模型在 4 个开源数据集集中的表现,结果显示 CatBoost 模型在一些数据集上拥有更好的预测能力以及更快的速度,适合于分类变量与连续变量异构的数据集。目前,CatBoost 模型已经应用在天文学、金融、营销、医学、生物学、心理学以及交通工程等领域^[27-28]。

因此,本文针对共享电动自行车逆行行为开展研究,挖掘人-车-路-环境中多源要素对逆行行为的影响。基于共享电动自行车运营企业提供的 GPS 轨迹数据,以路段逆行频次为因变量,使用梯度提升决策树 CatBoost 模型建立路段逆行频次影响模型,并利用可解释性机器学习框架 SHAP 解析各要素交互影响关系,剖析道路条件、交通状态、公共交通设施、出行时段、人口属性及土地利用性质等因素对路段逆行频次的影响。基于共享电动自行车轨迹数据与可解释性机器学习结合的方法为共享电动自行车风险骑行行为的研究提供新思路,揭示其影响要素和作用程度,为进一步提升电动自行车安全运营管理水平及交通设施的优化提供支撑。

1 数据基础

1.1 数据获取

数据来源包含四部分:①共享电动自行车运营企业提供的订单轨迹数据;②数字地图路网数据;③通过地图服务平台抓取的兴趣点(POI)数据;④通过街景地图提取的道路条件数据。研究将多源数据进行清洗和处理,搭建逆行行为影响特征数据库。

1.1.1 共享电动自行车轨迹数据

轨迹数据来源于中国某品牌共享电动自行车服务商提供的用户订单轨迹数据,时间范围为 2020 年 5 月和 7 月,共计 62 d。该品牌共享电动自行车在湖南省长沙市平均日骑行量约 26 500 次,产生约 2 500 万个轨迹点。研究选取长沙市中心城区芙蓉区作为研究区域,该区地处长沙市政治经济文化中心,其辖区内道路条件、交通状态及土地利用性质多样、共享电动自行车骑行量较大,可为影响作用分析提供丰富的数据来源。图 1 为芙蓉区某工作日全天




图 1 长沙市芙蓉区某工作日轨迹点热图

Fig. 1 Heat Map of Trajectory Points on a Working Day in Furong District, Changsha City

的轨迹点热图,对该区域轨迹点采样频率和间距进行统计,图 2(a)表明大多数轨迹采样频率为 3 s 和 10 s,图 2(b)表明 2 个相邻轨迹点间距离小于 25 m 的比例达 63%,为逆行行为的判定奠定了基础。





图 2 轨迹点采样统计

Fig. 2 Statistics of Trajectory Points Sampling

1.1.2 路网数据

研究区域的路网数据通过开源地图平台 Open Street Map 获取,路网数据内容包括道路(边)、节点(端点)、道路长度、道路方位角及单双向标识等属性,用于计算道路条件相关特征变量。为尽可能减少路段逆行频次出现“零膨胀”影响,筛选骑行量较大的 872 条道路路段(其中单向路 334 条,双向路 538 条)作为研究对象。

1.1.3 特征变量数据

研究围绕影响共享电动自行车逆行行为的人-

车-路-环境要素开展。查阅风险行为影响的相关文献^[5,9,20],从人口属性、出行时段、交通状态、道路条件、公共交通设施及土地利用性质等方面构成特征变量,解析逆行行为的影响要素和作用程度。

人口属性选取性别比例作为特征变量,通过订单轨迹数据获得骑行人性别信息,以路段上所有共享电动自行车出行中男性占比代表性别比例。

交通状态选取共享电动自行车平均骑行速度、平均加速度、平均减速度作为特征变量。在速度特征中,利用轨迹数据计算路段平均骑行速度。在某路段,依次计算轨迹点速度、轨迹平均速度、路段平均骑行速度。在轨迹链 i 中,轨迹点 $P_{i,j}$ 的点速度 $v_{i,j}$ 用该点 $P_{i,j}$ 与其相邻轨迹点 $P_{i,j+1}$ 间的区间速度代替,如式(1)所示

$$v_{i,j} = \frac{d_{i,j+1} - d_{i,j}}{t_{i,j+1} - t_{i,j}} \quad (1)$$

式中: $d_{i,j}$ 、 $d_{i,j+1}$ 为轨迹点 $P_{i,j}$ 、 $P_{i,j+1}$ 的位移; $t_{i,j+1} - t_{i,j}$ 为轨迹点 $P_{i,j}$ 与 $P_{i,j+1}$ 的时间间隔。

基于此计算轨迹链 i 的轨迹平均速度 v_i ,如式(2)所示

$$v_i = \frac{1}{N_i} \sum_{j=1}^{N_i} v_{i,j} \quad (2)$$

式中: N_i 为轨迹链 i 中轨迹点的数量。

最后计算路段平均骑行速度 $\bar{v}$,如式(3)所示

$$\bar{v} = \frac{1}{N_{\text{total}}} \sum_{i=1}^{N_{\text{total}}} v_i \quad (3)$$

式中: N_{total} 为该路段的总骑行量。

在速度变化中,将平均加减速速度作为特征变量。研究采用相邻轨迹点速度差与时间间隔的比值来表征加速度,在某路段上的某轨迹链 i 中,轨迹点 $P_{i,j}$ 的加速度 $a_{i,j}$ 如式(4)所示

$$a_{i,j} = \frac{v_{i,j+1} - v_{i,j}}{t_{i,j+1} - t_{i,j}} \quad (4)$$

式中: $v_{i,j}$ 、 $v_{i,j+1}$ 分别为前后两点 $P_{i,j}$ 、 $P_{i,j+1}$ 的轨迹点速度; $t_{i,j+1} - t_{i,j}$ 为前后两点 $P_{i,j}$ 与 $P_{i,j+1}$ 的时间间隔。

当 $a_{i,j}$ 大于 0 时骑行者加速骑行; $a_{i,j}$ 小于 0 时骑行者减速骑行。与路段平均骑行速度计算相似,其后计算轨迹平均加速度,最终得到路段平均加速度 $\bar{a}_{\text{acc}}$ 、路段平均减速度 $\bar{a}_{\text{dec}}$ 。

道路条件,选取机非分隔形式、非机动车道宽度与过街通道间距作为特征变量。机非分隔形式与非机动车道宽度属性通过百度街景地图读取,提取过街通道间距表征过街设施的便利性。研究通过百度街景地图统计路段中存在的人行横道、人行天桥、地

下通道等过街设施数量,并结合道路长度、单双向标识与机非分隔形式计算各个路段过街通道的平均间距。值得注意的是,当路段为双向路或无机非分隔的单向路时,由于缺乏物理隔离设施,电动自行车可在任意位置过街,定义该条件下过街通道间距为 0;当路段为单向路且存在机非分隔时,以路段长度除以过街设施数量加 1 的比值(即过街通道的平均距离)来表征过街通道间距。

公共交通设施和土地利用性质,选取公共交通设施与各类土地利用设施作为特征变量,采用路段不同类型兴趣点(POD)数量来表征。兴趣点 POI 数

据来源于高德地图 API,采集时间为 2020 年 5 月,各类 POI 实现路段聚合,以设施数量作为特征变量取值。其中,公共交通设施包括位于路侧的地面公交车站及地铁站出入口,土地利用性质包括与共享电动自行车骑行相关的 POI,如公司、教育、娱乐、金融、餐饮、政府机构、住宿、医疗、住宅、购物等。依据设施影响程度,采用路段邻近匹配方法实现 POI 路段聚合,道路周围 20 m 范围内的地面公交站将被聚合,地铁站与各类土地利用 POI 则考虑 50 m 的聚合范围。

综上多种特征变量,其描述性统计如表 1 所示。

表 1 特征变量数据描述统计

Table 1 Descriptive Statistics of Features Data

特征变量		平均值	标准差	最小值	最大值	数据源
因变量	逆行频次	3.456	4.871	0	79	订单轨迹数据
分类变量	工作日/节假日	0:节假日(47.63%);1:工作日(52.37%)				订单轨迹数据
	出行时段	1:7~9 时(11.35%);2:9~11 时(10.87%);3:11~13 时(11.15%); 4:13~15 时(11.06%);5:15~17 时(10.99%);6:17~19 时(11.57%); 7:19~21 时(11.29%);8:21~23 时(11.07%);9:23~7(+1d)时(10.65%)				订单轨迹数据
	机非分隔形式	0:无机非分隔(47.30%);1:标线机非分隔(40.87%); 2:护栏机非分隔(5.28%);3:绿化带机非分隔(6.54%)				百度街景地图
	非机动车道宽度	0:无非机动车道(47.05%);1:窄非机动车道(27.43%); 2:宽非机动车道(25.51%)				百度街景地图
连续变量	性别(男性)比例	0.591	0.271	0.000	1.000	订单轨迹数据
	平均骑行速度/(km·h ⁻¹)	10.787	4.428	0.157	27.522	订单轨迹数据
	平均加速度/(m·s ⁻²)	0.325	0.265	0.000	4.596	订单轨迹数据
	平均减速度/(m·s ⁻²)	-0.290	0.214	-4.413	0.000	订单轨迹数据
	过街通道间距/m	167.881	161.231	0.000	1 169.791	百度街景地图
	公交地铁站数量	0.375	0.701	0.000	6.000	高德地图 API
	公司	4.843	12.970	0.000	131.000	高德地图 API
	教育	2.057	3.923	0.000	30.000	高德地图 API
	娱乐	0.740	1.557	0.000	14.000	高德地图 API
	金融	0.907	1.998	0.000	18.000	高德地图 API
	餐饮	6.209	9.775	0.000	97.000	高德地图 API
	政府机构	1.189	2.659	0.000	23.000	高德地图 API
	住宿	1.949	5.616	0.000	75.000	高德地图 API
	医疗	1.194	2.473	0.000	43.000	高德地图 API
	住宅	0.917	1.488	0.000	11.000	高德地图 API
	购物	14.020	23.835	0.000	237.000	高德地图 API

1.2 数据处理

基于轨迹数据实现逆行行为的精准快速判定是研究的关键,数据处理主要包含轨迹数据切分、轨迹数据清洗、轨迹地图匹配及逆行行为判定 4 个步骤。

1.2.1 轨迹数据切分

研究区域范围原始订单记录数量 516 293 条,去除信息缺失(如性别年龄不详、开关锁经纬度缺

失、无轨迹信息等)订单记录 65 845 条,数据清洗前共获得有效轨迹 450 448 条。

为了确保轨迹映射到地理信息系统,需要将订单数据切分成相互独立的轨迹点,其中每个轨迹点拥有唯一的经纬度坐标。如表 2 所示,切分后每个轨迹点数据包括订单 ID、用户性别、用户年龄、轨迹点时间、轨迹点经度、纬度及起讫点标识。

表 2 订单轨迹数据切分
Table 2 Segmentation of Orders & Trajectory Data

订单 ID	性别	年龄	时间	经度/(°)	纬度/(°)	起讫点标识
C0000001	女	20	2020-05-01 (11:38:23)	112.947 393	28.204 963	1(起点)
C0000001	女	20	2020-05-01 (11:38:29)	112.947 383	28.204 970	0(轨迹点)
C0000001	女	20	2020-05-01 (11:38:32)	112.947 385	28.204 971	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮
C0000001	女	20	2020-05-01 (11:43:07)	112.948 391	28.205 793	2(讫点)

1.2.2 轨迹数据清洗

共享电动自行车的 GPS 轨迹点可能会受到城市高楼建筑物遮挡等外界因素的干扰而出现数据异常,表现为过大地偏离真实位置或丢失,进而导致轨迹点无法有效映射位置信息。本文依据如下规则清洗轨迹数据,考虑到异常识别的准确度与宽容度并尽可能多地保留有效轨迹点,对轨迹链进行遍历,当前轨迹点与其前一点分别为 P_i 、 P_{i-1} :①针对漂移点:当 $d(P_i - P_{i-1}) > kt(P_i - P_{i-1})$ 时,删除轨迹点 P_i ^[29];②针对缺失点:当 $t(P_i - P_{i-1}) > 60$ s 时,截断轨迹点 P_i 作为新轨迹子链;③针对轨迹链:经过(1)、(2)处理后筛选大于 5 个轨迹点的轨迹子链^[20]。

其中, $d(\cdot)$ 为相邻轨迹点距离函数, $t(\cdot)$ 为相邻轨迹点时间差函数, k 为宽容速度上限,研究中 k 取值为 $35\text{ km} \cdot \text{h}^{-1}$ 。经过轨迹数据清洗获得有效轨迹链 232 947 条(多条轨迹子链视为 1 条轨迹链),有效轨迹占比为 51.71%。

1.2.3 轨迹地图匹配

轨迹地图匹配目的是为每个轨迹点增加与其相匹配的路段编号标识,即轨迹点匹配后无需借助数字地图即可获得其所在位置的道路信息,借鉴 Luan 等^[20,30-31]地图匹配框架,确定地图匹配过程如下:

(1)索引,按照时间序列索引轨迹子链及子链中的轨迹点。

(2)匹配,采用最近邻匹配算法,每个轨迹点都与路网交叉计算,以投影距离最小的路段作为匹配目标。

(3)优化,匹配的轨迹点可能存在部分误差,参考文献[31]将匹配投影距离大于 20 m 的轨迹点删除,优化轨迹链匹配结果。

1.2.4 逆行行为判定

本文参考 Luan 等^[20]提出的共享单车逆行识别

方法,结合电动自行车特点,判定骑行方向与正常交通流行驶方向相反的骑行行为,逆行行为判定分为单向路和双向路的判定。

(1)单向路逆行判定。如图 3(a)所示,单向路具有确定的方位角($0^\circ \sim 360^\circ$,以正东方向为 0° ,逆时针方向增大)。当轨迹点骑行方向角与道路方位角差值超过阈值时将该点识别为逆行点,单向路逆行判定算法(算法 1)如下:

步骤 1:按时间序列索引轨迹链的 N 个轨迹点。

步骤 2:依次计算轨迹点 P_i ($i=1,2,\dots,N$) 与骑行方向角 φ_i 与道路方位角 ω 的方位差 $|\varphi_i - \omega|$;如果方位差 $|\varphi_i - \omega|$ 满足 $|\varphi_i - \omega| \in [d_1, d_2]$, $d_1 = 180^\circ - \alpha_d$, $d_2 = 180^\circ + \alpha_d$,则轨迹点 P_i 识别为逆行点;否则轨迹点 P_i 识别为正常骑行点。

步骤 3:当超过 50%轨迹点识别为逆行点时,判定轨迹子链为逆行。

其中, 180° 为 $|\varphi_i - \omega|$ 的预期值, α_d 为 $|\varphi_i - \omega|$ 的容许浮动值,研究中选取 α_d 为 45° 。

(2)双向路逆行判定。如图 3(b)所示,双向路允许双向通行因而没有确定的方向角,逆行表现为在目标方向的道路左侧移动。因此定义路段的临时方位向量,使用几何方法判定逆行。判定算法(算法 2)如下:

步骤 1:按时间序列索引轨迹链的 N 个轨迹点。

步骤 2:定义路段一端点 P_s 到另一端点 P_e 的临时方位向量 $\boldsymbol{a} = P_s P_e = (\boldsymbol{a}_x, \boldsymbol{a}_y)$;依次定义轨迹点 P_i ($i=1,2,\dots,N$) 到路段一端点 P_e 的骑行方向向量 $\boldsymbol{b}_i = P_s P_i = (\boldsymbol{b}_x, \boldsymbol{b}_y)$;如果满足 $\boldsymbol{a} \times \boldsymbol{b}_i = \boldsymbol{a}_x \boldsymbol{b}_y - \boldsymbol{a}_y \boldsymbol{b}_x > 0$,则轨迹点 P_i 识别为逆行点;否则轨迹点 P_i 识别为正常骑行点。

步骤 3:当超过 50%轨迹点识别为逆行点时,判定轨迹子链为逆行。

1.3 数据库搭建

将所有轨迹进行逆行判定后,以路段为索引计算路段逆行频次以反映逆行行为的严重程度。同时匹配所有类型变量数据,每个路段匹配工作日/节假日(2 个纬度)与时段(9 个维度)生成 18 个样本,并筛选出行轨迹量大于 0 的样本,最终构建由 14 442 个样本组成的逆行行为影响特征数据库,数据库结构如表 3 所示。

2 机器学习模型与可解释机器学习框架

2.1 CatBoost 模型

机器学习中决策树类的模型具有很好的数据兼




图 3 逆行行为识别示例

Fig. 3 Examples of Reverse Riding Identification

容性,不需要对输入特征进行归一化,受多重共线性影响较小,并且能够通过一定方法对模型输出进行解释^[32]。其中梯度提升决策升树 GBDT 是一种弱学习器集成强学习器的加性决策树算法^[33]。GBDT 算法以分类回归树(Classification and Regression Trees, CART)作为弱学习器,通过旧学习器损失函数梯度下降方向不断迭代新学习器来训练模型。训练过程中,每轮迭代根据当前预测值与实际值残差进行下一轮预测,最终将所有预测相加作为最终结果。GBDT 加性模型如式(5)所示

$$f_k(x)=\sum_{k=1}^N T(x;\theta_k) \tag{5}$$

式中: $T(x;\theta_k)$ 为 CART 决策树弱学习器; θ_k 为决策树参数; N 为决策树个数。

经过多轮迭代 CART 得到最终模型。GBDT 具有预测精度高的特点,并且适合于低维度、非线性、连续/分类变量混合的数据,已经被广泛应用于工业生产生活中。随着机器学习不断发展,目前基于 GBDT 已经形成更为先进的梯度提升学习算法,其中以 XGBoost、LightGBM 和 CatBoost 为代表的高级模型算法在数据挖掘中表现出很好的效果。

CatBoost 是由 Yandex 公司于 2017 年 4 月发布的一种机器学习模型^[23]。其名称由“Categorical”和“Boosting”的缩写组成,是基于 GBDT 模型框架实现的适用于分类变量与连续变量混合的改进模

表 3 逆行行为影响特征数据库

Table 3 Database of Reverse Riding Behavior Influence Factors

类型	符号	特征变量	变量类型	
风险骑行行为	Y	路段逆行频次	连续	
人口属性	x_1	性别(男性)比例	连续	
出行时段	x_2	工作日/节假日	分类	0 (节假日)
				1 (工作日)
	x_3	时段	分类	1 (07:00~09:00]
				2 (09:00~11:00]
				3 (11:00~13:00]
				4 (13:00~15:00]
				5 (15:00~17:00]
				6 (17:00~19:00]
				7 (19:00~21:00]
				8 (21:00~23:00]
9 (23:00~07:00(+1 d)]				
交通状态	x_4	平均骑行速度/ ($\text{km}\cdot\text{h}^{-1}$)	连续	
	x_5	平均加速度/ ($\text{m}\cdot\text{s}^{-2}$)	连续	
	x_6	平均减速度/ ($\text{m}\cdot\text{s}^{-2}$)	连续	
道路条件	x_7	机非分隔形式	分类	0 (无机非分隔)
				1 (标线机非分隔)
				2 (护栏机非分隔)
				3 (绿化带机非分隔)
	x_8	非机动车道宽度	分类	0 (无非机动车道)
				1 (窄非机动车道)
2 (宽非机动车道)				
x_9	过街通道间距/m	连续		
公共交通设施	x_{10}	公交站、地铁站数量	连续	
土地利用性质 (各类 POI 数量)	x_{11}	公司	连续	
	x_{12}	教育	连续	
	x_{13}	娱乐	连续	
	x_{14}	金融	连续	
	x_{15}	餐饮	连续	
	x_{16}	政府机构	连续	
	x_{17}	住宿	连续	
	x_{18}	医疗	连续	
	x_{19}	住宅	连续	
	x_{20}	购物	连续	

型。CatBoost 以对称决策树为基学习器,超参数较少,鲁棒性强,准确性较高。与其他加性决策树机器学习模型相比,CatBoost 采用排序提升(Ordered Boosting)的方法抵抗预测偏移,如算法 3 所示:

步骤 1:输入 n 个样本 $\{(x_i, y_i)\}_{i=1}^n$, I 棵决策树,以及数列 $\{1, 2, \dots, n\}$ 的随机排序 σ 。

步骤 2:在第 $t(t=1,2,\dots,I)$ 棵决策树中,分别对每个样本 $x_i(i=1,2,\dots,n)$ 训练一个不包含 x_i 的模型 M_i ,计算模型 M_i 关于样本 x_i 的残差 $r_i=y_i-M_{\sigma(i)-1}(x_i)$,并使用该残差来训练基学习器 $\Delta M=A_{\text{LearnModel}}((x_j,r_j):\sigma(j)\leq i),j=1,2,\dots,n$ 。更新模型 $M_i=M_i+\Delta M$ 。

步骤 3:对 I 棵决策树进行训练,输出最终模型 M_n 。

其中, ΔM 为 $A_{\text{LearnModel}}(\cdot)$ 基学习器的输出。

另外,CatBoost 使用独创的分类型特征处理算法生成新的数值型特征,根据式(6)将分类变量转化为数值变量,可有效降低过拟合和克服预测偏移的问题。令 $\sigma=[\sigma_1,\dots,\sigma_n]$ 为样本的随机排列,生成的数值变量 $\hat{x}_{\sigma_p}$,即

$$\hat{x}_{\sigma_p} = \frac{\sum_{j=1}^{p-1} [x_{\sigma_j} = x_{\sigma_p}] y_{\sigma_j} + qH}{\sum_{j=1}^{p-1} [x_{\sigma_j} = x_{\sigma_p}] y_{\sigma_j} + q} \quad j,p=1,2,\dots,n \quad (6)$$

式中: $x_{\sigma_j},x_{\sigma_p}$ 为 σ 排序中 j 或 p 位置的样本; y_{σ_j} 为对应样本的因变量; $[\cdot]$ 为艾佛森括号,表示当 $x_{\sigma_j}=x_{\sigma_p}$ 时值为 1,否则为 0; H 为先验分布项; q 为先验项的权重系数。

另外,模型使用中,分类变量处理和数据集训练可以同步进行,大幅提升了特征处理的效率^[34]。在本文中,首先通过机器学习拟合训练集特征变量与逆行频次的复杂关系并输出逆行频次预测值,其次在测试集上验证预测效果,最后利用解释器解析预测逆行的要素特征影响关系。

2.2 SHAP 可解释机器学习框架

SHAP(SHapley Additive exPlanations)是一种解释模型预测的统一框架^[35],用于事后解析复杂黑箱机器学习模型的预测输出,提高模型预测结果的可信度,揭示特征与预测值间的复杂影响关系。

SHAP 可解释机器学习框架是基于合作博弈论中用于描述所有变量特征边际贡献 Shapley 值理论的加性解释模型。对于每个预测样本的各个特征,生成对应预测值的 SHAP 值,等价于特征对样本的影响。

设 x_a 为 n 维样本 x 的第 a 个特征,SHAP 框架的本质是用加性模型 $G(x)$ 拟合需要解释的训练器 $F(x)$,如式(7)所示

$$F(x)=G(x)=\phi_{\text{base}}+\sum_{i=1}^n \phi_i \quad (7)$$

式中: ϕ_{base} 为模型对样本的预测基准,等于模型预测值的均值; ϕ_i 为 x_i 的 SHAP 值,其计算方法如式(8)所示

$$\phi_i = \sum_S \frac{|S|! (n-|S|-1)!}{n!} (F(S \cup \{x_i\}) - F(S)) \quad (8)$$

$S \subseteq \{x_1, x_2, \dots, x_n\} / x_i$

式中: $\{x_1, x_2, \dots, x_n\}$ 为所有输入特征的集合; S 为除去特征 x_i 得到的特征子集。

SHAP 值反映了特征 x_a 在不同特征子集中的边际贡献,即当 SHAP 值 >0 ,说明该特征提升了预测值,有正向作用;反之,该特征有负向作用。

3 模型构建与结果分析

3.1 逆行频次特征分布

图 4 所示因变量路段逆行频次特征分布表明,81%路段逆行频次小于 5 次,整体近似负指数分布。




图 4 路段逆行频次分布

Fig. 4 Distribution of Road Reverse Riding Frequency

3.2 路段逆行频次影响模型构建

研究选择 CatBoost 模型构建路段逆行频次影响模型,构建流程分为特征变量选择、参数调优和模型评价 3 个步骤。

3.2.1 模型构建与参数调优

研究依据路段逆行频次连续且数据库中分类变量与连续变量异构的特点,选择 CatBoost 模型回归算法,考虑人口属性、出行时段、交通状态、道路条件、公共交通设施、土地利用性质方面的多类型特征变量,构建路段逆行频次影响模型。特征变量选择中,各特征变量分别与逆行频次进行双变量相关性检验,结果显示所有特征均与逆行频次存在显著性相关关系($P<0.001$)。研究将数据集划分为训练集与测试集,划分比例为 8:2,用于模型拟合训练与模型性能评价。参数调优可有效防止过拟合,提升模型性能。本文采用参数网格搜索与五折交叉验证进行参数调优,降低模型随机影响。

3.2.2 模型性能评价方法

本文选取评价指标均方根误差 E_r (RMSE)、平均绝对误差 E_a (MAE)和决定系数 R_s (R-Square)作为测试集与预测结果的度量,评价模型性能水平。其中均方根误差与平均绝对误差代表误差水平,越接近 0 模型性能越好;决定系数反映模型对因变量变化的解释程度,越接近 1 模型性能越好。评价指标定义如下:

(1)均方根误差 E_r 为

$$E_r = \sqrt{\frac{1}{N_t} \sum_{i=1}^{N_t} (y_i - \hat{y}_i)^2}$$

(9)

(2)平均绝对误差 E_a 为

$$E_a = \frac{1}{N_t} \sum_{i=1}^{N_t} |y_i - \hat{y}_i|$$

(10)

(3)决定系数 R_s 为

$$R_s = 1 - \frac{\sum_{i=1}^{N_t} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{N_t} (y_i - \bar{y})^2}$$

(11)

式中: N_t 为测试集样本数量; y_i 为测试样本; $\hat{y}_i$ 为预测样本; $\bar{y}$ 为所有测试集样本的平均值。

3.3 模型结果分析

3.3.1 回归模型选取

本文构建传统统计学方法负二项回归模型与三种基于加性决策树的机器学习 XGBoost、LightGBM、CatBoost 模型进行比较,验证模型预测能力。另外,为了消除机器学习划分训练集与测试集的随机影响,对 3 种机器学习模型更换随机状态进行 100 次循环测试,最终获得模型性能评价指标如表 4 所示。

表 4 模型评价指标统计
Table 4 Statistics of Model Evaluation Index

模型	E_r			E_a			R_s		
	平均值	最大值	最小值	平均值	最大值	最小值	平均值	最大值	最小值
负二项回归	13.719			2.907			0.524		
CatBoost	2.608	2.891	2.447	1.643	1.705	1.579	0.714	0.762	0.672
XGBoost	2.660	2.912	2.487	1.671	1.747	1.606	0.703	0.750	0.654
LightGBM	2.683	3.046	2.485	1.677	1.788	1.602	0.698	0.744	0.651

注:CatBoost 参数{learning_rate=0.1,iterations=1 500,depth=8,gamma=0.1,subsample=0.75,l2_leaf_reg=15};XGBoost 参数{learning_rate=0.1,n_estimators=200,max_depth=8,gamma=0.1,min_child_weight=7,subsample=0.8};LightGBM 参数{learning_rate=0.1,max_depth=10,num_leaves=40,subsample=0.6,feature_fraction=0.7,bagging_fraction=0.8}。

比较模型各评价指标统计平均值可知,CatBoost 模型均方根误差与平均绝对误差最低($E_r=2.608$ 次, $E_a=1.643$ 次),同时决定系数最高($R_s=0.714$),表明机器学习模型性能优于负二项回归模型,CatBoost 模型更适合进行路段逆行频次预测,拥有较好的回归预测能力。

3.3.2 逆行影响分析

为了探究重要特征与逆行频次间的影响作用,研究基于 SHAP 可解释机器学习框架对训练后的 CatBoost 模型进行解释,解析特征变量对逆行频次预测的综合影响作用,以实现共享电动自行车逆行行为影响分析与诊断。

首先,观察 SHAP 特征概要图,图 5 表明模型所有特征变量中前 10 个重要特征由大到小依次为:工作日/节假日、性别(男性)比例、餐饮、过街通道间距、时段、平均加速度、公交地铁站、公司、娱乐、平均减速度。另外,SHAP 特征概要图中每点代表样本在相应特征上的 SHAP 值,颜色则表示样本自身特

征值的大小,如在分类变量工作日/节假日中,工作日对逆行频次呈现正向影响,节假日则呈现负向作用。从餐饮设施特征来看,设施数量越多对于逆行频次的发生影响程度越大。

由图 5 可以看出:出行时段方面,工作日/节假日是影响逆行的主要因素,工作日下的 SHAP 值显著高于节假日,表明工作日时更易发生逆行行为。人口属性方面,男性比例大小对逆行频次的影响没有明显倾向趋势,即男性和女性都可能产生逆行,其具体的影响结果需要进一步探究。土地利用方面,道路周围餐饮设施越多,逆行行为发生概率越大;同理,公司、娱乐、教育、购物、住宿、医疗、住宅、金融等设施对逆行行为亦具有一定影响。公共交通设施方面,地面公交站与地铁站出入口越多,对逆行行为的正向影响越大,这与公共交通设施对共享电动自行车的吸引有关。为了进一步理解特征与逆行的影响关系,绘制各属性单特征 SHAP 部分依赖(Partial Dependence Plot, PDP)研究特征对预测值的边际




图 5 SHAP 特征概要

Fig. 5 SHAP Summary Plot of Factors

效应。SHAP 部分依赖图横坐标为特征值,主纵坐标为相应的 SHAP 值,次纵坐标为一定区间内的 SHAP 平均值。

图 6 为公共交通设施与部分土地利用性质的部分依赖图。公共交通设施方面,图 6(a)显示了公交地铁站数量对逆行频次的影响:当公交地铁站数量不大于 2 时,SHAP 平均值上升;随后,SHAP 平均值相对平稳;当公交地铁站数量增至 6 时,SHAP 平均值再次显著上升。结果表明,逆行频次随着公交地铁站数量增加而增加。

土地利用性质方面,图 6(b)~(d)分别为餐饮、公司和购物设施对逆行的影响,均表现为在一定范围内设施数量与逆行频次呈现正相关,超过某阈值后 SHAP 平均值开始下降,但基本都维持大于 0 的趋势。表明路段上餐饮、公司和购物等设施对逆行的影响是非线性的,在一定数量范围内,路段上设施越集中越容易发生逆行行为。这与共享单车逆行的影响规律具有一定的相似性^[20],理解这种非线性影响对于不同用地性质区域采用地域差异化政策,对提升非机动车骑行的安全至关重要。

图 7 为出行时段、人口属性、交通状态的部分依赖图。出行时段方面,图 7(a)为时段的逆行影响,各个时段对逆行频次的影响存在明显差别,早高峰(标签 1[07:00~09:00])与晚高峰(标签 6[17:00~19:00])SHAP 值大于 0 且大于其他时段,说明早晚高峰期间的逆行行为频次较高;日间平峰及夜间 SHAP 平均值小于 0,表明该时段与逆行存在负相




图 6 公共交通设施与土地利用性质 SHAP 部分依赖图

Fig. 6 SHAP Partial Dependence Plot of Public Transport Facilities and Land Use Attributes

关系。

人口属性方面,图 7(b)显示了性别比例对逆行行为频次的影响。骑行者男性比例变化幅度较大且呈现非线性影响,该比例在 0.3~0.8 时逆行频次增多,而仅有男性或女性时逆行降低。表明男性女性混合时逆行次数多,可能由于男女性生理、心理的差别导致骑行的速度、环境、安全认知存在差异,可能存在相互影响,其复杂的影响机理可在未来作进一步研究。




图7 人口属性、出行时段、交通状态 SHAP 部分依赖图
Fig.7 SHAP Partial Dependence Plot of Demographic Attributes, Travel Time and Traffic Conditions

交通状态方面,图 7(c)、(d)显示了速度变化与逆行的相关关系,平均加速度与平均减速速度部分依赖图具有相似的趋势。加速度小于 $0.3\text{ m}\cdot\text{s}^{-2}$ 时不易发生逆行行为,处于 $0.3\sim1.0\text{ m}\cdot\text{s}^{-2}$ 间时易发生逆行行为,增至 $1.0\text{ m}\cdot\text{s}^{-2}$ 后其影响作用较小。图 7(e)显示了骑行速度与逆行的相关关系,当骑行速度在 $6\sim16\text{ km}\cdot\text{h}^{-1}$ 时与逆行存在正相关关系,骑行速度较低或较高时存在负相关关系。综合分析交通状态表明,骑行速度与逆行行为相互影响,在骑行速度较低且加速度较小的路段中,其交通流可能处于接近饱和状态,逆行发生的概率较低。当骑行速度较快且加速度较大时可能交通流量较小,骑行者受到道路周围设施吸引较小,不易发生逆行。当骑行速度适中且加速度频繁变化时,交通流内部互相干扰多可能处于交通量较大区域,骑行者会受到公共交通设施和多种土地利用性质的影响而发生更多逆行行为;同时,逆行时因受到顺行交通流的阻力,骑行难以提升速度,也会表现出一定范围的速度、加速度变化。

图 8 为道路条件的部分依赖图。图 8(a)显示了过街通道间距对逆行频次的影响。首先,过街通道间距为 0 时 SHAP 平均值大于 0,表明在无物理隔离路段,为了方便到达目的地,骑行者会随时穿越道路,过街掉头并发生逆行行为;其次,当过街通道间距在 $50\sim400\text{ m}$ 时 SHAP 平均值小于 0,表明在此过街通道间距的区间内,骑行者可以接受的额外出行距离,骑行者更倾向于选择安全的绕行方式到达目的地;另外,当过街通道间距在 $400\sim600\text{ m}$ 时逆行频次显著增加,表明该间距已经超过骑行者的忍耐距离,从而出现较多的逆行行为;最后,当过街通道间距大于 600 m 时,该特征对逆行行为的影响作用较小。通过查看导致该结果的样本发现长距离过街通道间距主要为跨江跨河桥、高架桥等特殊道路,无过街设施情况下非机动车骑行者自然不可改变骑行方向。因此,过街通道间距的合理设计对非机动车安全的影响十分重要。

另外,机非分隔形式特征部分依赖图如图 8(b)所示,机非分隔形式对逆行频次也存在一定影响。可以看出无非机动车道(标签 0)与标线机非分隔(标签 1)的 SHAP 平均值接近于 0,表明标线分隔的非机动车道与无施画非机动车道影响相似,且与共享电动自行车逆行关系较小。护栏机非分隔(标签 2)与绿化带机非分隔(标签 3)则与逆行频次呈现相反影响。护栏分隔一般出现在次干路与支路,此




图 8 道路条件部分依赖图

Fig. 8 SHAP Partial Dependence Plot of Road Conditions

类道路电动自行车过街较为便利,且护栏分隔的非机动车道一般较窄,逆行的安全风险较大,使骑行人感到危险,故逆行概率较低。而绿化带分隔的非机动车道一般出现在路幅较宽的道路,此类路段过街通道间距较大,过街便利性较差,同时绿化带的机非分隔为逆行提供了安全空间,发生逆行的概率较大。因此,在规划非机动车道时应该考虑合理的非机动车道宽度与便捷的过街设施,同时也可看出机非分隔形式与其他特征存在交互影响的可能,未来研究中需要进一步考虑多特征对逆行频次的交互影响。

4 结 语

研究基于共享电动自行车 GPS 轨迹数据,准确识别骑行轨迹中的逆行行为,以路段逆行频次为因变量,使用机器学习 CatBoost 模型建立路段逆行频次影响模型,结合 SHAP 可解释性机器学习框架可视觉解析逆行行为的人-车-路-环境多元要素的影响关系,为共享电动自行车安全运营管理、交通设施优化及靶向治理精准施策提供理论支撑。主要研究结论如下:

(1)基于机器学习模型构建的路段逆行频次影响模型预测能力均优于负二项回归模型,其中,CatBoost 模型均方根误差为 2.608 次,平均绝对误差为 1.643 次,决定系数为 0.714,表明该模型具有更强的预测回归性能,更适于预测路段逆行频次。

(2)出行时段是影响逆行的最主要特征,工作日与早晚高峰时段的通勤出行更容易发生逆行。

(3)路段周围公共交通设施数量及餐饮、住宿、公司、购物等设施数量与逆行频次存在非线性影响关系。设施数量在一定范围内与逆行行为存在正影响作用,超过一定范围则可能负影响或正负波动。

(4)过街通道间距对逆行有较大影响,过街通道间距在 50~400 m 时不易发生逆行,过街通道间距在 400~600 m 或非机动车道无物理隔离设施可随处过街时容易发生逆行,过街通道间距大于 600 m 时逆行影响呈现不稳定的作用。

(5)存在机非分隔的路段,标线机非分隔对逆行行为无影响,护栏机非分隔逆行行为发生概率较低,绿化带机非分隔的逆行发生概率较高。

(6)对于交通状态,当骑行速度、加速度较低或较高时与逆行行为存在负相关关系,当骑行速度在 6~16 km·h⁻¹ 以及加速度在 0.3~1.0 m·s⁻² 时与逆行行为存在正相关关系。

研究结论为共享电动自行车安全运营管理改善提出针对性的建议。例如:①加强现场执法、宣传教育应对工作日早晚高峰 07:00~09:00、17:00~19:00 逆行频发的现象;②合理规划设计道路交通设施,建议非机动车出行集中的路段适当增加道路过街设施,将过街通道间距控制在 400 m 以内,在道路条件允许和非机动车流量适宜时多采用物理隔离的非机动车设施等;③合理规划骑行空间和停车空间,如在餐饮、公司、购物等重要影响设施密集的路段适当增加过街通道,加强路边停车管理,在公交地铁站出口附近增加停车点等;④对于公共交通设施与土地利用性质的非线性影响,应考虑采用地域差异化的政策,保障和提升共享电动自行车骑行安全。

此外,研究发现共享电动自行车与共享单车存在相似的特点,例如两者拥有相似的逆行比例(共享电动自行车为 33.9%,共享单车为 31.7%^[20]),并且这 2 种交通方式逆行频次都会受到公共交通设施、土地利用性等特征的非线性影响,但影响程度存在差别。因此在一定程度上可以将共享电动自行车与共享单车的管理措施互相借鉴,未来需要进一步开展深入的分析研究,推动非机动车安全形势的综合改善。

综上,本文通过轨迹大数据与机器学习方法,挖掘多元特征下的共享电动自行车逆行行为要素影响规律,为风险骑行行为研究提供了新的思路和方法。为了进一步深入探究共享电动自行车逆行行为的影

响关系,后续研究将开展多因素交互的影响分析,获取更加精细的道路设施条件,考虑兴趣区面积以消除兴趣点数量的空间偏差,以及研究骑行心理、态度等人因对逆行行为的影响。另外,未来可将逆行行为影响研究推广到其他风险骑行行为的研究,助力共享电动自行车安全健康发展。

参考文献:

References:

- [1] 新京报. 全国政协委员谷树忠:建议引导和支持共享电单车行业发展[EB/OL]. (2020-05-22) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1667367282189990788>.
The Beijing News. Gu Shuzhong, Member of the National Committee of the Chinese People's Political Consultative Conference: It's Suggested to Guide and Support the Shared E-bike Industry [EB/OL]. (2020-05-22) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1667367282189990788>.
- [2] 新华网. 我国电动自行车社会保有量接近3亿辆[EB/OL]. (2020-11-20) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1683861077944588599>.
Xinhuanet. Chinese Social Ownership of Electric Bicycles is Close to 300 Million [EB/OL]. (2020-11-20) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1683861077944588599>.
- [3] 艾媒生活与出行产业研究中心. 2020中国共享电单车安全管理专题研究报告[R]. 广州:艾媒咨询, 2020.
iiMedia Life and Travel Industry Research Center. 2020 China the Safety Management of Shared Electric Bicycle Research Report [R]. Guangzhou: iiMedia Research, 2020.
- [4] 环球网. 年死亡人数超8千人专家呼吁国家立法强制电动自行车骑乘者佩戴安全头盔[EB/OL]. (2020-12-02) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1684954314581734262>.
Global Times. The Annual Death Toll is Over 8 000. Experts Call for National Legislation to Force E-bike Riders to Wear Safety Helmets [EB/OL]. (2020-12-02) [2021-04-20]. <https://baijiahao.baidu.com/s?id=1684954314581734262>.
- [5] 柏璐. 城市道路电动自行车交通特性与安全影响研究[D]. 南京:东南大学, 2017.
BAI Lu. Research on Traffic Characteristics and Safety Effect of Electric Bicycles in Urban Streets [D]. Nanjing: Southeast University, 2017.
- [6] 王曼丽. 城市道路电动自行车的交通安全特性分析[D]. 成都:西南交通大学, 2010.
WANG Man-li. Safety Analysis of Electric Bicycle in Urban Road [D]. Chengdu: Southwest Jiaotong University, 2010.
- [7] 贾海亮. 电动自行车交通特性研究[D]. 成都:西南交通大学, 2014.
JIA Hai-liang. The Research on Traffic Characteristics of Electric Bicycle [D]. Chengdu: Southwest Jiaotong University, 2014.
- [8] JIANG Q, LI C. The Measures Study of Electric Bicycle's Hidden Safety Danger in Traffic in Moderate City [C] // IEEE. International Conference on Industrial Control & Electronics Engineering. New York: IEEE, 2012: 23-25.
- [9] 赵桂范, 刘明敏, 刘磊, 等. 人-车-路系统下电动自行车安全性试验[J]. 中国公路学报, 2014, 27(2): 105-111.
ZHAO Gui-fan, LIU Ming-min, LIU Lei, et al. Experimental Research on Safety of Electric Bicycles Under Driver-vehicle-road System [J]. China Journal of Highway and Transport, 2014, 27(2): 105-111.
- [10] ZHAO X, REN G, DU X, et al. Characteristics and Risk of Violation Behavior of Non-motorists at Signalized Intersections [J]. Journal of Southeast University (English Edition), 2011, 27(4): 423-429.
- [11] YAO L, WU C X. Traffic Safety for Electric Bike Riders in China Attitudes, Risk Perception, and Aberrant Riding Behaviors [J]. Transportation Research Record, 2012 (2314): 49-56.
- [12] STIMPSON J P, HE Z, WILSON F A. Bicyclists Found at Fault for Bicycle Crashes in California [J]. The American Journal of Emergency Medicine, 2016, 34(8): 1699-1701.
- [13] 李岩, 胡文斌, 张兴雨, 等. 逆行非机动车骑行者的安全生理学特性[J]. 中国安全科学学报, 2017, 27(9): 14-19.
LI Yan, HU Wen-bin, ZHANG Xing-yu, et al. Safety Physiology Characteristics of Bicyclists on Reverse Riding Conditions [J]. China Safety Science Journal, 2017, 27(9): 14-19.
- [14] LU W, SCOTT D M, DALUMPINES R. Understanding Bike Share Cyclist Route Choice Using GPS Data: Comparing Dominant Routes and Shortest Paths [J]. Journal of Transport Geography, 2018, 71: 172-181.
- [15] ROMANILLOS G, GÓMEZ B M, AUSTWICK M Z, et al. The Pulse of the Cycling City: Visualising Madrid Bike Share System GPS Routes and Cycling Flow [J]. Journal of Maps, 2018, 14(1): 34-43.

- [16] LI C M, DAI Z X, PENG W X, et al. Green Travel Mode: Trajectory Data Cleansing Method for Shared Electric Bicycles [J]. *Sustainability*, 2019, 11 (5): 1429.
- [17] WAMBURU J, LEE S, HAJIESMAILI M H, et al. Ride Substitution Using Electric Bike Sharing: Feasibility, Cost, and Carbon Analysis [J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2021, 5 (1): 1-28.
- [18] LANGFORD B C, CHEN J L, CHERRY C R. Risky Riding: Naturalistic Methods Comparing Safety Behavior from Conventional Bicycle Riders and Electric Bike Riders [J]. *Accident Analysis & Prevention*, 2015, 82: 220-226.
- [19] 马晓磊,栾 森,李 萌,等.一种基于自行车轨迹数据的逆行行为识别方法:CN110634290B[P]. 2020-06-09.
MA Xiao-lei, LUAN Sen, LI Meng, et al. A Wrong Way Riding Recognition Method Based on Bicycle Trajectory Data: CN110634290B [P]. 2020-06-09.
- [20] LUAN S, LI M, LI X, et al. Effects of Built Environment on Bicycle Wrong Way Riding Behavior: A Data-Driven Approach [J]. *Accident Analysis & Prevention*, 2020, 144: 105613.
- [21] CHEN T Q, GUESTRIN C. XGBoost: A Scalable Tree Boosting System [C] // KRISHNAPURAM B, SHAH M. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York: Association for Computing Machinery, 2016: 785-794.
- [22] KE G L, MENG Q, FINLEY T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree [C] // GUYON I, LUXBURG U V, BENGIO S, et al. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. Cambridge: MIT Press, 2017: 3146-3154.
- [23] DOROGUSH A V, ERSHOV V, GULIN A. CatBoost: Gradient Boosting with Categorical Features Support [J/OL]. *Machine Learning* [2018-10-24]. <https://arxiv.org/abs/1810.11363v1>.
- [24] AYOUB J, YANG X J, ZHOU F. Modeling Dispositional and Initial Learned Trust in Automated Vehicles with Predictability and Explainability [J]. *Transportation Research Part F*, 2021, 77: 102-116.
- [25] 薛清文,蒋愚明,陆 键.基于轨迹数据的危险驾驶行为识别方法[J]. *中国公路学报*, 2020, 33(6): 84-94.
XUE Qing-wen, JIANG Yu-ming, LU Jian. Risky Driving Behavior Recognition Based on Trajectory Data [J]. *China Journal of Highway and Transport*, 2020, 33 (6): 84-94.
- [26] ANGHEL A, PAPANDREOU N, PARNELL T, et al. Benchmarking and Optimization of Gradient Boosting Decision Tree Algorithms [J]. *Machine Learning* [2018-12-12]. <https://arxiv.org/abs/1809.04559>.
- [27] FEI X H, FANG Y, LING Q. Discrimination of Excessive Exhaust Emissions of Vehicles Based on Catboost Algorithm [C] // TENG R, ZHU X. *2020 Chinese Control and Decision Conference (CCDC)*. New York: IEEE, 2020: 4396-4401.
- [28] HANCOCK J T, KHOSHGOFTAAR T M. CatBoost for Big Data: An Interdisciplinary Review [J]. *Journal of Big Data*, 2020, 7 (1): 1-45.
- [29] 杨彦青.电动自行车轨迹数据分析与可视化相关技术研究[D]. 沈阳:沈阳理工大学, 2019.
YANG Yan-qing. *Research on Data Analysis and Visualization Technology of Electric Bicycle Track* [D]. Shenyang: Shenyang Ligong University, 2019.
- [30] YUAN J, ZHENG Y, ZHANG C Y, et al. An Interactive-voting Based Map Matching Algorithm [C] // BILOF R. *2010 Eleventh International Conference on Mobile Data Management*. New York: IEEE, 2010: 43-52.
- [31] HE T F, BAO J, LI R Y, et al. Detecting Vehicle Illegal Parking Events Using Sharing Bikes' Trajectories [C] // GUO Y K, FAROOQ F. *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. New York: Association for Computing Machinery, 2018: 340-349.
- [32] WIKIPEDIA CONTRIBUTORS. Decision Tree Learning [EB/OL]. (2021-06-05) [2021-07-08]. https://en.wikipedia.org/w/index.php?title=Decision_tree_learning&oldid=1032085462.
- [33] FRIEDMAN J H. Greedy Function Approximation: A Gradient Boosting Machine [J]. *The Annals of Statistics*, 2001, 29 (5): 1189-1232.
- [34] PROKHORENKOVA L, GUSEV G, VOROBEOV A, et al. CatBoost: Unbiased Boosting with Categorical Features [C] // BENGIO S, WALLACH H, LAROCHELLE H, et al. *Advances in Neural Information Processing Systems 31 (NeurIPS 2018)*. Cambridge: MIT Press, 2018: 6638-6648.
- [35] LUNDBERG S M, LEE S I. A Unified Approach to Interpreting Model Predictions [C] // GUYON I, LUXBURG U V, BENGIO S, et al. *Advances in Neural Information Processing Systems 30 (NIPS 2017)*. Cambridge: MIT Press, 2017: 4768-4777.